ENGINEERING RESEARCH / CASE-001

Hybrid RAG 구축 방법

RETRIEVAL · EMBEDDING · ACCESS CONTROL

116

SEARCH POINTS

153

ACCESS POLICIES

3

RETRIEVAL SOURCES

《마지막 기록: 사라진 공동체》 | 별도 PDF 보고서

SOURCE: 7 DOCX REPORTS + VERIFIED DEV RECORDS

보고서 개요

Hybrid RAG 구축 방법 / 핵심 지표와 검증 범위

116	153	3
SEARCH POINTS	ACCESS POLICIES	RETRIEVAL SOURCES

BGE-M3 임베딩, Qdrant Dense/BM25, Neo4j 그래프 관계 검색, RRF 결합, 게임 상태 기반 접근 정책을 일관된 처리 경로로 설명합니다.

1. 설계 목적과 원칙

플레이어는 대화 상대 NPC에게 자연어로 질문하지만, NPC가 말할 수 있는 사실은 사전에 정의한 사건 문서·인물 지식·진술과 현재 게임 상태로 제한해야 합니다. 따라서 생성 모델에 전체 사건 원문을 넘기지 않고, 신뢰 가능한 검색 후보만 추출한 뒤 접근 제어를 재검증하는 구조로 설계했습니다.

핵심 구조 Dense 의미 검색 + 한국어 BM25 키워드 검색 + Neo4j 관계 검색 → RRF 통합 → 정책 검증 → LLM 생성 → 응답 검증

2. 사전 데이터 준비

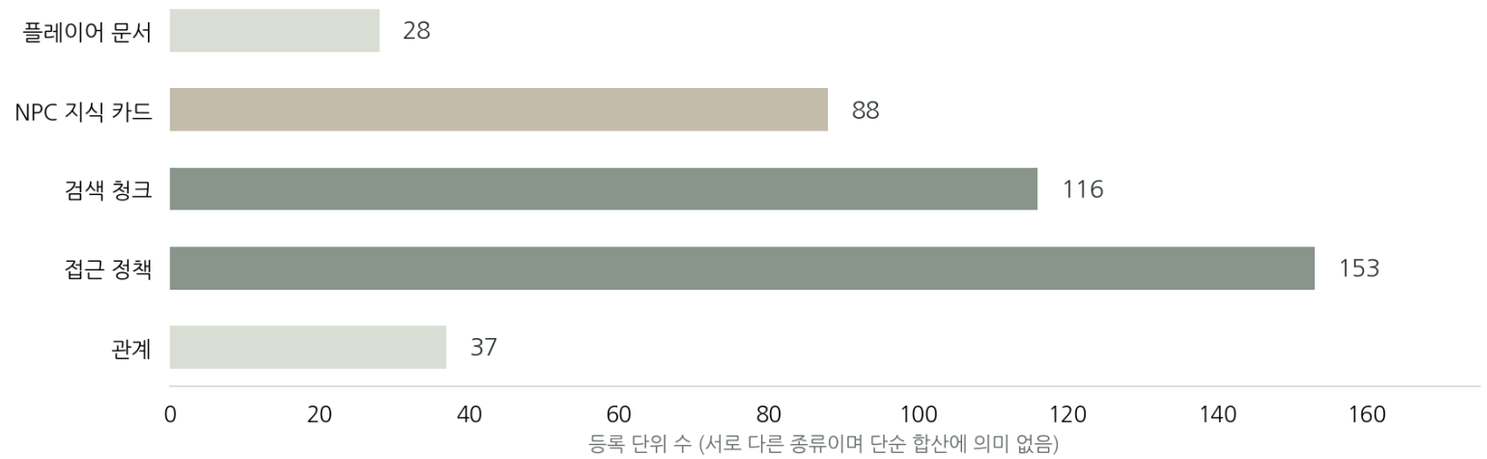


FIG. 01 검색 입력 데이터와 접근 정책 규모

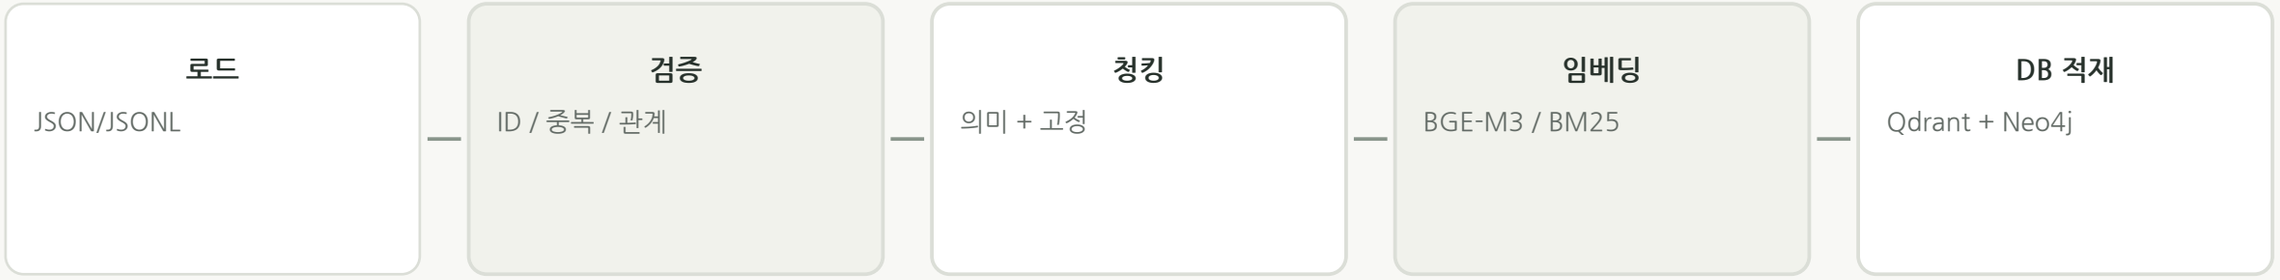
원본 데이터	규모	주요 역할
플레이어 문서	28개	증거 원문, 세계관, 보충 문서
NPC 지식 카드	88개	NPC별 진술·페르소나 연결 사실
Hybrid RAG 청크	116개	Qdrant 포인트로 검색 가능한 정규화 단위

2. 사전 데이터 준비 / 계속

원본 데이터	규모	주요 역할
접근 정책	153개	증거·제시·플래그·캐릭터별 공개 조건
그래프 관계	37개	인물·증거·사건의 신뢰 관계
대화 인물 / 증거	10명 / 10개	C01~C10 / E01~E10

규모는 CASE-001 v7.1 및 Issue #32 평가 기준입니다. 비공개 원본은 .local/case001_v7_1에 별도 배치하며 공개 GitHub 저장소에 올리지 않습니다.

3. 적재 파이프라인



1단계: JSON/JSONL 원본을 로딩하고 사건 ID, 인물 ID, 문서 ID, 참조 관계, 정책 ID를 교차 검증합니다.

2단계: 플레이어 문서와 NPC 지식 카드를 별도 소스 유형으로 분리합니다. NPC 관리자 원본의 비밀 필드는 검색 인덱스에 직접 적재하지 않습니다.

3단계: 의미 기반 및 고정 길이 청킹을 병행합니다. 프로젝트 구성 기록상 min=120, max=800, overlap=80, 의미 분할 기준 0.65를 사용합니다.

4단계: Ollama BGE-M3로 1,024차원 Dense 벡터를 생성하고 Kiwi 형태소 기반 BM25 Sparse 벡터를 구성합니다.

5단계: Qdrant case001_rag_v1에 동일 UUID의 포인트와 메타데이터를 적재하고, Neo4j에는 엔티티·관계·증거 보유 연결을 적재합니다.

6단계: Dry Run → Apply → Dry Run 순으로 동기화 무결성을 점검하며, 정상 동기화 시 TOTAL CHANGES: 0을 확인합니다.

4. Qdrant 인덱스 설계

설정	값	근거 / 의미
컬렉션	case001_rag_v1	사건 단위 검색 컬렉션
Dense vector	dense / 1024차원 / COSINE	BGE-M3 의미 벡터
Sparse vector	bm25 / IDF modifier	Kiwi 기반 한국어 희소 검색
포인트 키	UUID (point_id)	원본·정책 재검증용 안정 식별자
원본 구분	player_document / npc_knowledge	교차 사용·정보 노출 방지
권한 메타데이터	policy_id, access_scope, character_id	검색 이후 서버 정책 검증의 입력

5. 실시간 검색 및 생성 흐름

정책 확인
NPC / 상태

검색
Dense·BM25·Graph

RRF 융합
후보 순위 결합

권한 재검증
허가 문서만

LLM 생성
출처·응답 검증

순서	처리 단계	핵심 동작
01	NPC 및 세션 확인	게임 phase, 선택 NPC, unlocked 상태, 세션 소유권 확인
02	검색 전 접근 정책	질문 주제·NPC 지식 범위 및 GameState 기반 필터
03	Dense 검색	질문 임베딩 → Qdrant 코사인 유사도 후보
04	BM25 검색	Kiwi 토큰화 → Qdrant Sparse 후보
05	Graph Retrieval	엔티티 추출 → Neo4j 관계·증거 연결 후보
06	RRF 통합	세 후보의 순위를 합산, 중복 제거 및 출처 보존
07	최종 권한 검증	서버 신뢰 UUID, 증거·제시·플래그·NPC 조건 재검증

5. 실시간 검색 및 생성 흐름 / 계속

순서	처리 단계	핵심 동작
08	LLM 메시지 구성	승인된 근거만 포함, 진술과 확정 사실 구분
09	응답 검사·영속화	근거 및 비공개 정보 검증 → SQLite 대화/상태 저장

RRF 수식: score(d) = Σ 1 / (k + rank (d)); 구현의 기본 k=60. Dense/BM25의 문서 UUID와 Neo4j의 관계·증거 ID는 (종류, ID) 조합으로 분리해 잘못 합쳐지지 않도록 합니다.

6. 접근 제어와 환각 억제

정책이 존재하지 않거나 실패하면 공개를 거부하는 fail-closed 원칙을 적용합니다.

수집하지 않은 증거, 해금되지 않은 NPC, 요구 플래그 미발급, 엔딩 전용 관계는 LLM 컨텍스트에서 제외합니다.

검색 결과의 UUID 및 본문을 서버 신뢰 원본과 대조하며, 문서 원본과 NPC 전용 카드의 자동 혼용을 금지합니다.

최종 LLM 입력에는 허가된 텍스트만 전달하고 내부 정책 메타데이터나 비공개 사건 원장에 접근하지 못하게 합니다.

LLM 생성 결과에서 인용 근거 및 비공개 사실의 노출 여부를 다시 검사합니다.

7. 품질·성능 평가

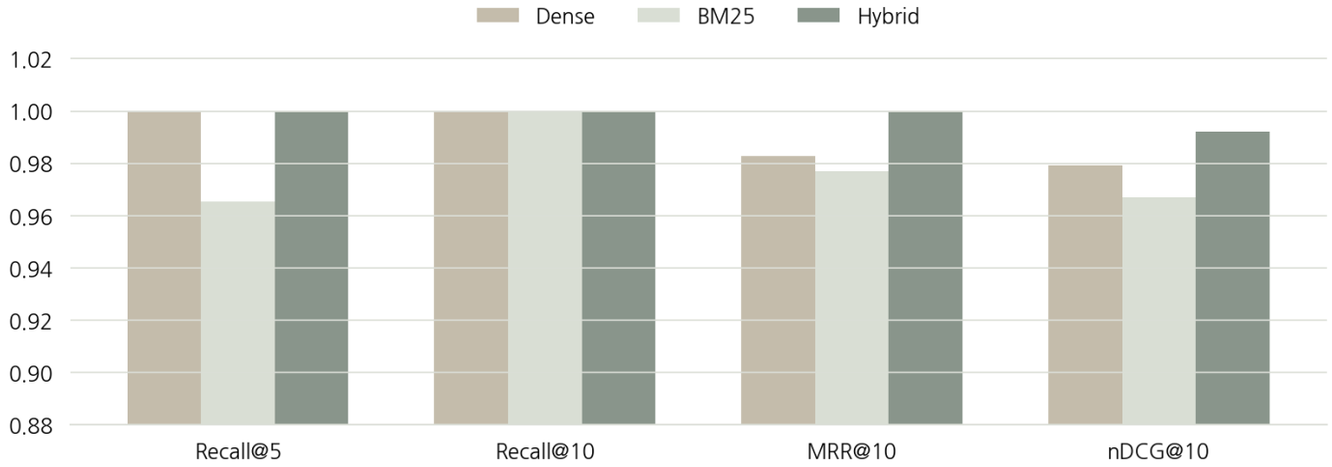


FIG. 02 Dense / BM25 / Hybrid 29문항 검색 지표

방식	Recall@5	MRR@10	nDCG@10
Dense	1.0000	0.9828	0.9793
BM25	0.9655	0.9770	0.9669
Hybrid	1.0000	1.0000	0.9921

7. 품질·성능 평가 / 계속

29문항 잠정 Gold Label 평가 기준이며 Dense+BM25 평가표입니다. 실제 NPC 응답 경로는 Neo4j 검색을 추가로 결합합니다. 이는 별개의 평가 범위이므로 위 수치를 3중 검색의 독립 실측으로 표시하지 않습니다.

성능 개선 PR #81은 워밍업 후 RAG 검색 평균을 약 6.47초에서 0.50초로 감소시켰습니다. LLM 생성 시간과 전체 사용자 체감 지연은 포함하지 않습니다.

8. 구축 재현 및 운영 점검

docker compose up -d 로 Qdrant·Neo4j 컨테이너를 실행합니다.

ollama pull bge-m3 및 필요한 생성 모델(qwen3:8b)을 준비합니다.

backend에서 uv sync --locked 후 Qdrant 컬렉션을 생성·검증합니다.

uv run python -m crimescene.db.data_pipeline --root ../.local/case001_v7_1 로 Dry Run을 수행합니다.

--apply를 사용해 적재한 후 Dry Run 재실행으로 변경사항 0건을 확인합니다.

허용·비허용 질문, NPC 전환, 증거 수집 전후의 검색·출처가 변하는지 검증합니다.

9. 미해결 과제

질문 다양성 확대, Gold Label 재검수, LLM 답변의 사실 일치도 및 자연스러움 평가, 콜드 스타트·동시 부하 p95 지연 측정, DEEP 엔딩 도달 가능성 검증이 남았습니다.

REFERENCE

업로드된 원본 보고서 및 dev 저장소 소스: https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN36-3rd-2Team/tree/dev

- 프로젝트 README / • 모듈 인터페이스
- RAGChunk 스키마 / • Qdrant 컬렉션 스키마
- Issue #32 RAG 평가 보고서 / • RAG 지연 최적화·회귀 검증 (PR #81)
- 팀원 로컬 실행 가이드

검토 메모 및 기준 자료

정확도 해석 경계

29문항의 Hybrid 수치는 Dense + BM25 RRF의 문서 검색 순위 평가입니다. Neo4j를 결합한 전체 응답 정확도 또는 생성 답변의 사실 일치도로 해석하면 안 됩니다.

출처: 업로드된 원본 02_RAG_구축_방법.docx, dev README 및 관련 PR (#75, #76, #78, #81, #82, #86). 보고서 편집 과정에서 새로운 로컬 환경 측정은 실행하지 않았습니다.