ENGINEERING RESEARCH / CASE-001

A/B 비교 실험 결과

OFFLINE EVALUATION · LATENCY COMPARISON

29

EVALUATION CASES

0.9921

HYBRID NDCG@10

0.50s

RAG AVG AFTER

SOURCE: 7 DOCX REPORTS + VERIFIED DEV RECORDS

보고서 개요

A/B 비교 실험 결과 / 핵심 지표와 검증 범위

29	0.9921	0.50s
EVALUATION CASES	HYBRID NDCG@10	RAG AVG AFTER

비교 실험 A(29문항 오프라인 검색 정확도), B(검색 지연 개선)와 별도 3문항 회귀 결과를 함께 제시합니다. 사용자 무작위 배정 A/B는 아닙니다.

1. 실험 명칭과 해석 범위

중요 이 프로젝트에서 기록된 결과는 실제 사용자 무작위 배정 A/B 테스트가 아닙니다. 동일 평가셋의 알고리즘 오프라인 비교와 최적화 전후 성능 관측을 A/B 형식으로 정리한 것입니다.

두 실험은 목적과 모집단이 다릅니다. 실험 A는 검색 정확도(29문항), 실험 B는 RAG 검색 지연(서로 다른 반복 측정 세트)을 비교했습니다. ‘사용자 만족도가 유의미하게 향상됐다’는 주장은 할 수 없습니다.

2. 비교 실험 A: 검색 알고리즘 품질

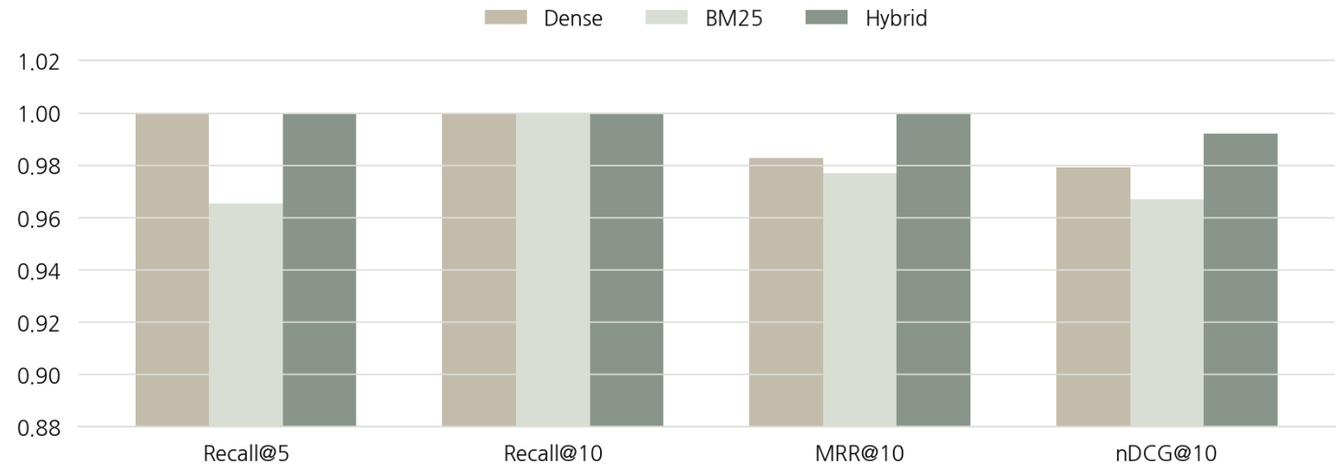


FIG. 01 29문항 비교 실험: 검색 방식별 품질

설계 항목	내용
비교 조건	A군: Dense(BGE-M3) / B군: Hybrid(Dense+BM25 RRF)
보조 조건	BM25 단독을 별도 대조군으로 수록
평가 대상	CASE-001 플레이어 문서 검색, 평가 질문 29개(v2)

2. 비교 실험 A: 검색 알고리즘 품질 / 계속

설계 항목	내용
기준 라벨	문서 UUID 기반 Gold Label: 독립 최종 검수 전
지표	Recall@5, Recall@10, MRR@10, nDCG@10
평가 단위	동일 질문에 대한 검색 순위 비교. LLM 응답 품질은 미포함

지표	A: Dense	B: Hybrid	B A
Recall@5	1.0000	1.0000	0.0000
Recall@10	1.0000	1.0000	0.0000
MRR@10	0.9828	1.0000	+0.0172
nDCG@10	0.9793	0.9921	+0.0128

해석: 평가 질문 29개에서 두 방식의 Top-5 재현율은 동일했지만 Hybrid가 첫 관련 문서 순위(MRR)와 순위 품질(nDCG)에서 더 높은 값을 기록했습니다. 단, 표본 규모와 임시 라벨 특성상 통계적 유의성 및 일반화는 판단할 수 없습니다.

3. 보조 비교: BM25 단독

지표	BM25	Hybrid	차이
Recall@5	0.9655	1.0000	+0.0345
Recall@10	1.0000	1.0000	0.0000
MRR@10	0.9770	1.0000	+0.0230
nDCG@10	0.9669	0.9921	+0.0252

4. 비교 실험 B: RAG 검색 속도

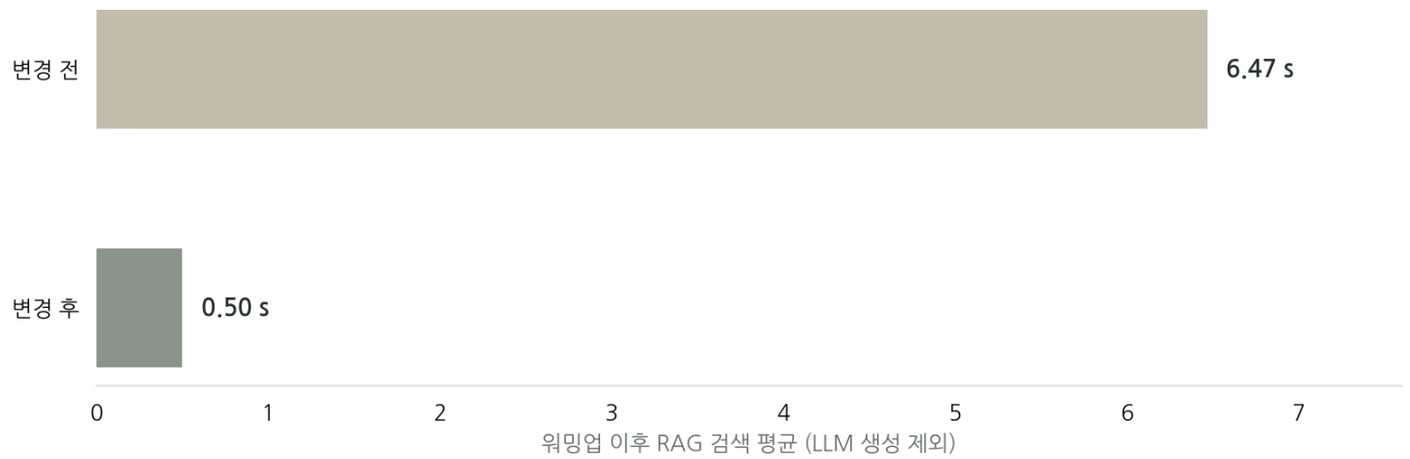


FIG. 02 검색 평균 지연 개선

PR #81은 검색 알고리즘 자체가 아니라 로컬 Qdrant 연결 지연에 집중했습니다. A군은 기존 환경의 관측 결과, B군은 127.0.0.1 기반으로 연결을 명시한 환경의 워밍업 후 관측 결과입니다.

측정 항목	A: 최적화 전	B: 최적화 후	비교
RAG 검색 평균	약 6.47초	약 0.50초	약 92.4% 감소(보고치)

4. 비교 실험 B: RAG 검색 속도 / 계속

측정 항목	A: 최적화 전	B: 최적화 후	비교
Qdrant Dense 요청	약 2,044ms	약 10~31ms	대폭 단축
Qdrant BM25 요청	약 2,048ms	약 6~31ms	대폭 단축
BM25 인코딩	약 1ms	약 1ms	유사

제약: 변경 전후를 같은 요청에 교차 무작위 적용한 실험이 아닙니다. 따라서 환경 편차·연결 상태·캐시·워밍업을 통제하지 못했고 LLM 답변 생성 시간도 포함하지 않습니다.

5. 추가 3문항 회귀 표본(별개 실험)

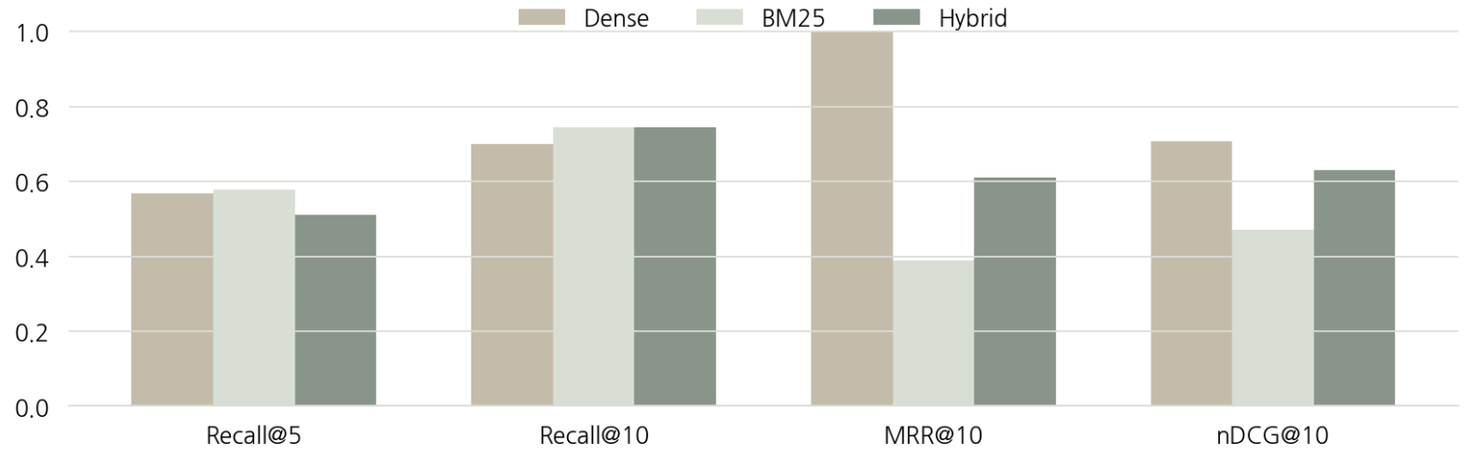


FIG. 03 별도 3문항 소규모 회귀: 상반된 결과도 포함

PR #81에서 후보 k=30, 결과 k=10, 질문 3개로 확인한 수치를 아래에 별도로 수록합니다. 29문항 평가와 질문·평가 목적이 달라 같은 표본에서 개선·저하를 주장할 수 없습니다.

방법	Recall@5	Recall@10	MRR@10	nDCG@10
Dense	0.567	0.700	1.000	0.708
BM25	0.578	0.744	0.389	0.472

5. 추가 3문항 회귀 표본(별개 실험) / 계속

방법	Recall@5	Recall@10	MRR@10	nDCG@10
Hybrid	0.511	0.744	0.611	0.630

이 작은 표본에서는 Hybrid의 Recall@5·MRR@10·nDCG@10이 Dense보다 낮습니다. 이는 RAG 성능이 질문 구성에 민감하다는 신호이므로 본 실험 보고서에 불리한 결과도 함께 유지합니다.

6. 엄밀한 사용자 A/B 실험이 아직 없는 이유

실제 사용자 집단에 대한 무작위 배정·노출 로그·샘플 크기 설정 기록이 없습니다.

각 변형의 동일 환경, 동일 하드웨어, 동일 질문·NPC·게임 상태별 시차 통제가 없습니다.

사용자별 지표(클리어율, 플레이 시간, 만족도, 이탈률)를 수집·검증한 기록이 없습니다.

통계적 신뢰구간·유의성 검정·사전 정의된 종료 기준이 없습니다.

7. 후속 A/B 실험 설계(제안, 미실행)

평가 설계
사전 표본수

조건 통제
같은 모델/환경

로그 수집
근거 일치도

통계 검정
95% CI

배포 게이트
누출 0건

항목	제안 실험안
주요 가설	Hybrid+Graph 검색이 Dense 단독보다 NPC 사실 일치도와 플레이 이해도를 개선한다
실험 단위	세션 단위 무작위 배정; 동일 NPC·게임 단계별 균형 배정
운영 조건	같은 모델·프롬프트·데이터 버전·인프라, 동일 질문 세트
1차 지표	전문가 블라인드 평가 근거 일치도, 비인가 사실 노출률
2차 지표	응답 p50/p95, NPC 말투 일관성, 증거 획득 성공률
안전 게이트	비인가 정보 노출 0건, 회귀 테스트 모두 통과
통계	표본수 사전 산정, 95% 신뢰구간, 다중 비교 관리

7. 후속 A/B 실험 설계(제안, 미실행) / 계속

항목	제안 실험안
판정 원칙	가설·표본·중단 기준 사전 등록 후 객관적인 차이로 채택

8. 결론

현재 근거로 판단할 수 있는 것은 “29문항의 잠정 검색 순위는 Hybrid가 Dense보다 일부 지표에서 우수했고, Qdrant 연결 지연을 줄여 RAG 검색 구간 평균이 단축됐다”는 점입니다.
사용자 행동에 대한 A/B 효과나 답변 품질의 통계적 우월성은 아직 검증되지 않았습니다.

REFERENCE

업로드된 원본 보고서 및 dev 저장소 소스: https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN36-3rd-2Team/tree/dev

- Issue #32 RAG 평가 보고서 / • RAG 품질·보안 평가 (PR #76)
- RAG 지연 최적화·회귀 검증 (PR #81)

검토 메모 및 기준 자료

평가 한계

29문항은 잠정 Gold Label 기반 오프라인 알고리즘 비교이며, 3문항 회귀는 모집단이 달라 직접 개선율 비교에 사용할 수 없습니다. 변경 전후 지연도 무작위 교차 실험이 아닌 서로 다른 반복 측정값입니다.

결론

오프라인 29문항에서 Hybrid의 순위 품질은 일부 지표에서 우수했습니다. 그러나 별도의 3문항 결과는 일관된 우월성을 보이지 않으므로, 실제 사용자 실험이나 LLM 답변 품질을 검증한 것으로 표현하면 안 됩니다.

출처: 업로드된 원본 05_AB_테스트_결과.docx, dev README 및 관련 PR (#75, #76, #78, #81, #82, #86). 보고서 편집 과정에서 새로운 로컬 환경 측정은 실행하지 않았습니다.