ENGINEERING RESEARCH / CASE-001

테스트 검증 결과

AUTOMATED TESTS · END-TO-END · SECURITY

1,559

PYTEST PASS

12

PLAYTEST PASS

0.50s

RAG AVG AFTER

SOURCE: 7 DOCX REPORTS + VERIFIED DEV RECORDS

보고서 개요

테스트 검증 결과 / 핵심 지표와 검증 범위

1,559	12	0.50s
PYTEST PASS	PLAYTEST PASS	RAG AVG AFTER

개발 과정에서 수행한 자동화 회귀, 실제 플레이, 검색 품질, 보안 및 지연 측정 결과를 하나의 검증 체계로 정리했습니다. 신규 테스트를 재실행한 문서가 아니라 기록된 결과를 시각적으로 재구성한 것입니다.

1. 결과 요약

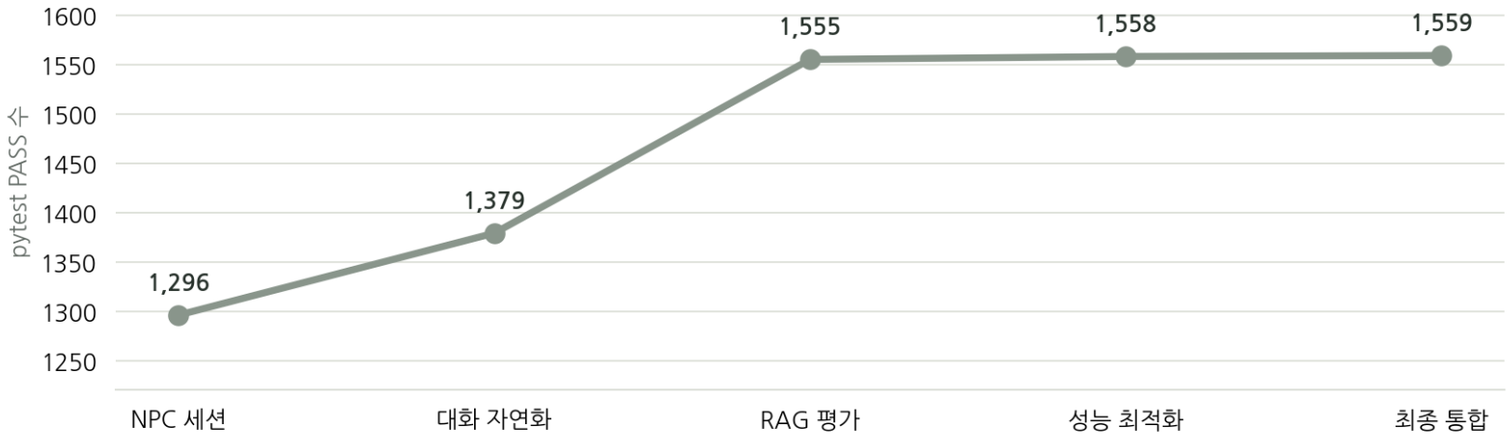


FIG. 01 PR 별 pytest 통과 수의 기록 추이

판정 주요 게임 흐름 및 자동화 회귀 테스트 통과. 다만 미실행 항목과 미확정 평가 라벨은 운영 품질 인증으로 간주하지 않습니다.

측정·검증 대상	확인된 결과	증빙 구분
pytest 전체 회귀	1,558 passed · 9 skipped	PR #81에 기록된 최종 수치
실제 플레이 E2E	12개 항목 PASS	PR #75 로컬 수동 검증

1. 결과 요약 / 계속

측정·검증 대상	확인된 결과	증빙 구분
증거·인물·점수	증거 10/10 · NPC 10/10 · 21/21점	PR #78 실제 RAG 및 로직 검증
RAG 검색 품질	Hybrid Recall@5 1.0000 / MRR@10 1.0000	29문항 잠정 평가
접근 제어	검증 대상 비인가 정보 노출 0건	PR #76 제한된 검증 범위
RAG 응답 전 검색 지연	약 6.47초 → 0.50초 (평균)	PR #81 반복 측정; LLM 생성 제외

2. 시험 범위와 증빙 등급

이 보고서는 dev 브랜치 및 2026-11-10까지 병합된 PR의 실행 기록을 정리했습니다. 작성 과정에서 로컬 Docker·Ollama·비공개 CASE-001 데이터를 다시 실행하지 않았으므로 아래 수치는 '저장소에 기록된 기존 결과'입니다.

구분	범위	한계
자동화 회귀	pytest·Ruff 및 기능별 예외/보안 테스트	9개 skipped의 개별 사유는 최신 로그에서 재확인 필요
로컬 실물 E2E	React-FastAPI-Ollama-Qdrant-Neo4j 연동	환경·장비·반복 횟수는 통제 실험이 아님
정확도 오프라인	질문 29개, 정답 UUID 기반 검색 순위	Gold Label 독립 검수 미완료
속도	워밍업 후 RAG 검색 구간 반복 측정	LLM 생성·UI 렌더링·네트워크 종단 지연 제외

3. 게임 기능별 검증

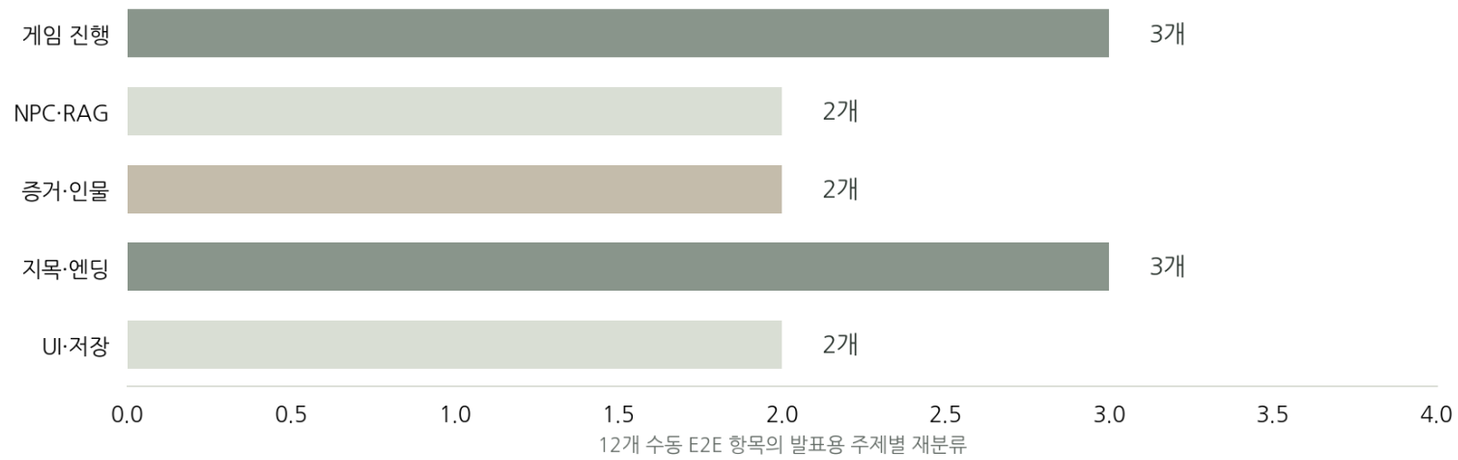


FIG. 02 12개 실제 플레이 E2E 항목의 기능별 구분

검증 ID	시나리오 / 수용 기준	결과·근거
TC-01	게임 생성 → 프롤로그 → 조사 단계 정상 전환	PASS / 수동 E2E
TC-02	해금 NPC 선택 및 자연어 질문·대화 기록	PASS / 수동 E2E
TC-03	게임 상태에 따른 증거 제시와 반응	PASS / 수동 E2E

3. 게임 기능별 검증 / 계속

검증 ID	시나리오 / 수용 기준	결과·근거
TC-04	E01~E10 10개 증거 모두 수집	10/10 PASS / 실제 RAG
TC-05	NPC C01~C10 해금 조건 충족	10/10 PASS / 실제 데이터
TC-06	증거 누적 점수와 진행률 일치	21/21점 PASS
TC-07	증거 5개·11점 미충족 시 지목 차단	PASS / 자동화 회귀
TC-08	오답 시 기회 1회 차감, 조사 단계 복귀	PASS / 수동 E2E
TC-09	정답 시 성공 엔딩, 3회 오답 시 실패	PASS / 수동 및 회귀
TC-10	새로고침 후 엔딩 복원·새 게임 초기화	PASS / 수동 E2E
TC-11	관계도 및 수첩에 허가된 정보만 표시	PASS / 범위 내 검증
TC-12	프론트엔드 프로덕션 빌드	PASS / npm run build

4. RAG 검색 정확도

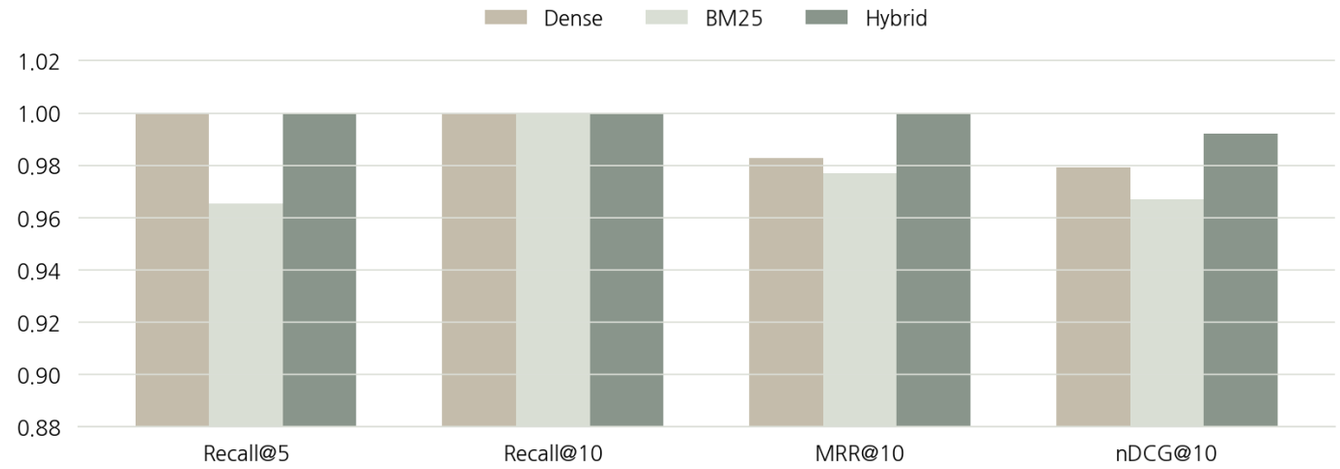


FIG. 03 29문항 RAG 검색 정확도 평가

Issue #32의 평가셋 v2는 질문 29개를 대상으로 Dense, BM25, Dense+BM25 RRF를 동일한 정답 UUID 기준으로 비교했습니다. ‘Hybrid’의 아래 값은 검색 순위 평가이며 생성 답변 품질 지표가 아닙니다.

방법	Recall@5	Recall@10	MRR@10	nDCG@10
Dense	1.0000	1.0000	0.9828	0.9793

4. RAG 검색 정확도 / 계속

방법	Recall@5	Recall@10	MRR@10	nDCG@10
BM25	0.9655	1.0000	0.9770	0.9669
Hybrid	1.0000	1.0000	1.0000	0.9921

Hybrid는 29문항 평가에서 정답 문서를 Top-5 안에 모두 포함했습니다. 다중 문서 질문 Q024·Q025에서는 일부 정답 문서의 순위 개선 여지가 남았습니다.

5. 보안·무결성 시험

시험 항목	목표	기록된 결과
NPC 지식 격리	NPC 간 권한 없는 카드·대화 유입 차단	PASS
검색 전·후 정책 적용	비인가 Qdrant/Graph 후보의 LLM 전달 방지	PASS
미해금·미수집 차단	해금 전 NPC·증거·문서·관계 사전 노출 방지	PASS
세션·revision	서버 소유권/낡은 요청/동시 중복 처리 차단	회귀 테스트 통과
정답 정보 분리	서버 전용 원장, 종료 전 진상 비공개	회귀 및 E2E 통과
DEEP 엔딩	정책 단위 차단 검증	정책 PASS, 실제 자격 갱신 미구현

6. 처리 시간 및 성능 회귀

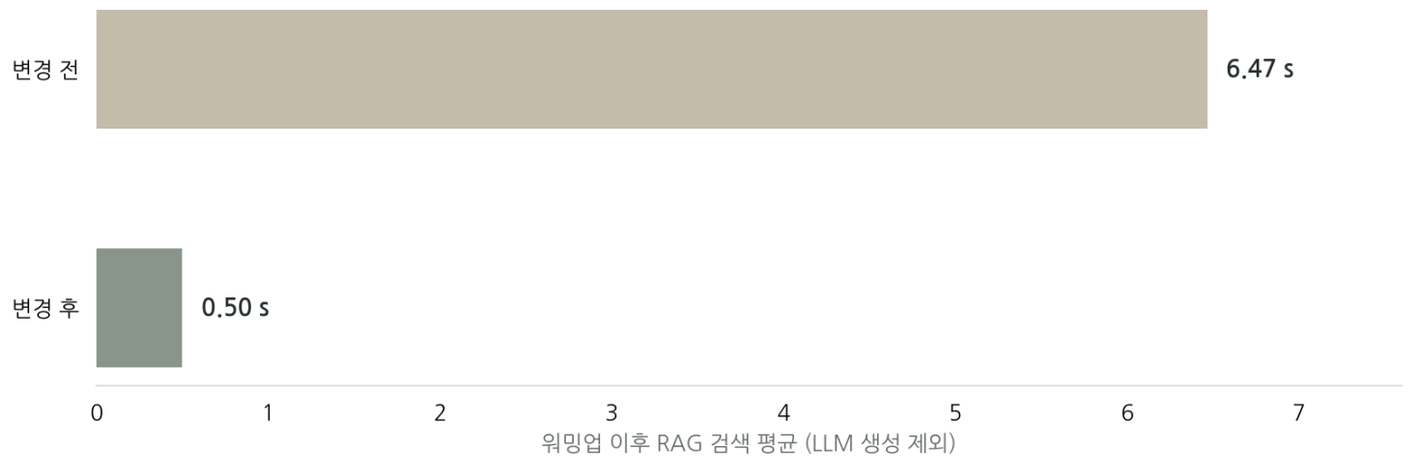


FIG. 04 RAG 검색 평균 최적화 전·후

측정 구간	변경 전	변경 후	판단
전체 RAG 검색 평균	약 6.47 s	약 0.50 s	PR 기록상 약 92.4% 개선
Dense Qdrant 요청	약 2,044 ms	약 10~31 ms	연결 지연 개선
BM25 Qdrant 요청	약 2,048 ms	약 6~31 ms	연결 지연 개선

6. 처리 시간 및 성능 회귀 / 계속

측정 구간	변경 전	변경 후	판단
BM25 인코딩	약 1 ms	약 1 ms	기존 대비 큰 변화 없음

로컬 연결 주소를 127.0.0.1:6333으로 명시한 후 측정한 결과입니다. 변경 전후 측정 세트가 다르고 하드웨어·캐시·워밍업 영향이 있으므로 엄밀한 인과 검증 수치로 해석하지 않습니다.

7. 잔여 리스크 및 조치 우선순위

우선	잔여 항목	후속 검증 방식
높음	Gold Label 독립 검수 및 더 큰 평가셋	NPC/상태/질문 유형별 블라인드 라벨링
높음	심층 엔딩 deep_eligible 갱신 경로 부재	조건 정의 후 엔딩 API E2E
중간	대화 반복·EMPTY_QUOTES·환각 방지 품질	정성평가와 답변 근거율 측정
중간	p95/p99 지연·콜드 스타트·동시접속	동일 환경 반복·부하 테스트
중간	9 skipped 사유·브라우저 호환성	CI 로그 및 PC/모바일 재검증

8. 재현 명령 및 판정 주의사항

백엔드: cd backend → uv sync --locked → uv run ruff check . → uv run pytest -q

프론트엔드: cd frontend → npm ci → npm run build → npm run spoiler

실물 검증: 별도 CASE-001 v7.1 데이터, 서버 정답 원장, Docker Qdrant·Neo4j, Ollama 모델이 필요하며 자격 증명은 공개 문서에 넣지 않습니다.

REFERENCE

업로드된 원본 보고서 및 dev 저장소 소스: https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN36-3rd-2Team/tree/dev

- 프로젝트 README / • RAG 지연 최적화·회귀 검증 (PR #81)
- 전체 게임 통합·플레이 E2E (PR #75) / • 게임 규칙 회귀 검증 (PR #78)
- RAG 품질·보안 평가 (PR #76) / • Issue #32 RAG 평가 보고서

검토 메모 및 기준 자료

최신 dev 기록 보완

PR #82 통합 기록의 pytest는 1,559 PASS / 9 SKIP입니다. 이 숫자는 기존 업로드 문서에 기록된 PR #81의 1,558 PASS / 9 SKIP보다 1건 많습니다. 서로 다른 시점의 결과이며 한 번의 동일 실행으로 합산하지 않습니다.

출처: 업로드된 원본 01_최종_테스트_결과.docx, dev README 및 관련 PR (#75, #76, #78, #81, #82, #86). 보고서 편집 과정에서 새로운 로컬 환경 측정은 실행하지 않았습니다.